

Lista II: Q1

Alberson Miranda

2022-11-25

```
# configurações
knitr::opts_chunk$set(
  fig.output = "70%"
)

# reproducibilidade
set.seed(1)

# pacotes
pacman::p_load(
  "ggplot2",
  "tsibble",
  "fable",
  "feasts",
  "fabletools",
  "urca"
)
```

1 MODELAGEM BOX-JENKINS: SÉRIE I

O primeiro passo é a importação e visualização da série. Como não há informação sobre o período, usarei diário e tentarei identificar a partir de um padrão sazonal, se houver.

```
# importando dados
load("data/lista II.RData")
data = data.frame(
  value = conjunto1[, 1],
  index = seq(
    as.Date("2000-01-01"),
```

```

    by = 1,
    length.out = length(conjunto1[, 1])
  )
) |> tsibble(index = index)


```

A série é compacta, ou seja, de amplitude baixa, não requerindo transformação para redução de variância.

```

# plot série
autoplot(data, .vars = value)

```



O segundo passo é testar se a série é estacionária no primeiro momento. Não há evidências de raiz unitária tanto nos testes quanto nos gráficos de autocorrelação. Para os testes ADF, iniciei com a especificação com tendência. Não sendo significativo o coeficiente τ_t , passei para a especificação com *drift*, sendo tanto o intercepto quanto $z.lag.1$ significativos, adoto esta como a correta especificação e, assim como nos testes de Phillips-Perron e KPSS, não há indicativo de raiz unitária.

```

# KPSS test
data |>
  features(value, unitroot_kpss)

```

```
# A tibble: 1 x 2
  kpss_stat kpss_pvalue
    <dbl>      <dbl>
1    0.108      0.1
```

```
# Phillips-Perron test
data |>
  features(value, unitroot_pp)
```

```
# A tibble: 1 x 2
  pp_stat pp_pvalue
    <dbl>      <dbl>
1   -6.43      0.01
```

```
# Augmented-Dickey-Fuller test
data |>
  (\(x) ur.df(x$value, selectlags = "AIC", type = "trend", lags = 12))() |>
  summary()
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression trend

Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)

Residuals:

Min	1Q	Median	3Q	Max
-0.0102211	-0.0022799	0.0000216	0.0020829	0.0102631

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.141e+01	2.057e+00	5.549	9.87e-08 ***
z.lag.1	-3.424e-01	6.171e-02	-5.549	9.87e-08 ***
tt	3.313e-06	4.807e-06	0.689	0.492
z.diff.lag	-8.474e-03	7.397e-02	-0.115	0.909

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.00356 on 184 degrees of freedom

Multiple R-squared: 0.171, Adjusted R-squared: 0.1574

F-statistic: 12.65 on 3 and 184 DF, p-value: 1.487e-07

Value of test-statistic is: -5.5495 10.2859 15.411

Critical values for test statistics:

	1pct	5pct	10pct
tau3	-3.99	-3.43	-3.13
phi2	6.22	4.75	4.07
phi3	8.43	6.49	5.47

```
data |>
  (\(x) ur.df(x$value, selectlags = "AIC", type = "drift", lags = 12))() |>
  summary()
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression drift

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.0101264	-0.0022878	-0.0000252	0.0020877	0.0103523

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	11.27905	2.04454	5.517	1.15e-07 ***
z.lag.1	-0.33838	0.06134	-5.517	1.15e-07 ***
z.diff.lag	-0.01060	0.07380	-0.144	0.886

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.003555 on 185 degrees of freedom
Multiple R-squared: 0.1688, Adjusted R-squared: 0.1598
F-statistic: 18.79 on 2 and 185 DF, p-value: 3.73e-08

Value of test-statistic is: -5.5166 15.2347


Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.46	-2.88	-2.57
phi1	6.52	4.63	3.81

A seguir, pode-se perceber decaimento na ACF e um pico na PACF, sugerindo um processo AR(1).


```
# ACF  
data |> ACF() |> autoplot()
```

Response variable not specified, automatically selected `var = value`



```
# ACF  
data |> PACF() |> autoplot()
```

Response variable not specified, automatically selected `var = value`



Além do AR(1), também realizei uma *grid search*, que consiste na estimação de todas as combinações possíveis de modelos ARIMA dada uma restrição de coeficientes. Neste caso, como a análise do correlograma sugere um AR(1), optei por uma restrição parcimoniosa, com no máximo 3 coeficientes (AR ou MA) e sem testar modelos integrados, uma vez que foi constatada a estacionaridade. Dentre os modelos estimados, o de menor critério de informação foi o AR(1), no mesmo sentido da análise visual do correlograma.

```
data_fit = data |>
  model(
    ar1 = ARIMA(
      value ~ 1 + pdq(1, 0, 0)
    ),
    search = ARIMA(
      value,
      stepwise = FALSE,
      trace = TRUE,
      order_constraint = p + q + P + Q <= 3 & (constant + d + D <= 1))
  )
```

ARIMA(0,0,0)(0,0,0)[7]+c -1589.386363

ARIMA(1,0,0)(0,0,0)[7]+c	-1700.363424
ARIMA(2,0,0)(0,0,0)[7]+c	-1698.315341
ARIMA(3,0,0)(0,0,0)[7]+c	-1695.712579
ARIMA(0,0,1)(0,0,0)[7]+c	-1668.586911
ARIMA(1,0,1)(0,0,0)[7]+c	-1698.303988
ARIMA(2,0,1)(0,0,0)[7]+c	-1696.822220
ARIMA(0,0,2)(0,0,0)[7]+c	-1682.955592
ARIMA(1,0,2)(0,0,0)[7]+c	-1696.222233
ARIMA(0,0,3)(0,0,0)[7]+c	-1695.230046
ARIMA(0,0,0)(1,0,0)[7]+c	-1585.461121
ARIMA(1,0,0)(1,0,0)[7]+c	-1696.000612
ARIMA(2,0,0)(1,0,0)[7]+c	-1693.062626
ARIMA(0,0,1)(1,0,0)[7]+c	-1663.280799
ARIMA(1,0,1)(1,0,0)[7]+c	-1693.950922
ARIMA(0,0,2)(1,0,0)[7]+c	-1678.426909
ARIMA(0,0,0)(2,0,0)[7]+c	-1578.757729
ARIMA(1,0,0)(2,0,0)[7]+c	-1688.504270
ARIMA(0,0,1)(2,0,0)[7]+c	-1656.733042
ARIMA(0,0,0)(0,0,1)[7]+c	-1588.036672
ARIMA(1,0,0)(0,0,1)[7]+c	-1699.009375
ARIMA(2,0,0)(0,0,1)[7]+c	-1697.025695
ARIMA(0,0,1)(0,0,1)[7]+c	-1666.716920
ARIMA(1,0,1)(0,0,1)[7]+c	-1696.968352
ARIMA(0,0,2)(0,0,1)[7]+c	-1681.620771
ARIMA(0,0,0)(1,0,1)[7]+c	-1595.850518
ARIMA(1,0,0)(1,0,1)[7]+c	-1697.251094
ARIMA(0,0,1)(1,0,1)[7]+c	-1667.413004
ARIMA(0,0,0)(2,0,1)[7]+c	Inf
ARIMA(0,0,0)(0,0,2)[7]+c	-1586.749289
ARIMA(1,0,0)(0,0,2)[7]+c	-1696.969600
ARIMA(0,0,1)(0,0,2)[7]+c	-1665.570336
ARIMA(0,0,0)(1,0,2)[7]+c	-1593.766397
ARIMA(0,0,0)(0,0,0)[7]	1982.061534
ARIMA(1,0,0)(0,0,0)[7]	Inf
ARIMA(2,0,0)(0,0,0)[7]	Inf
ARIMA(3,0,0)(0,0,0)[7]	Inf
ARIMA(0,0,1)(0,0,0)[7]	1725.595542
ARIMA(1,0,1)(0,0,0)[7]	Inf
ARIMA(2,0,1)(0,0,0)[7]	Inf
ARIMA(0,0,2)(0,0,0)[7]	1529.598405
ARIMA(1,0,2)(0,0,0)[7]	Inf
ARIMA(0,0,3)(0,0,0)[7]	1393.372344
ARIMA(0,0,0)(1,0,0)[7]	Inf


ARIMA(1,0,0)(1,0,0)[7]	Inf
ARIMA(2,0,0)(1,0,0)[7]	Inf
ARIMA(0,0,1)(1,0,0)[7]	Inf
ARIMA(1,0,1)(1,0,0)[7]	Inf
ARIMA(0,0,2)(1,0,0)[7]	Inf
ARIMA(0,0,0)(2,0,0)[7]	Inf
ARIMA(1,0,0)(2,0,0)[7]	Inf
ARIMA(0,0,1)(2,0,0)[7]	Inf
ARIMA(0,0,0)(0,0,1)[7]	1758.879724
ARIMA(1,0,0)(0,0,1)[7]	Inf
ARIMA(2,0,0)(0,0,1)[7]	Inf
ARIMA(0,0,1)(0,0,1)[7]	1555.857332
ARIMA(1,0,1)(0,0,1)[7]	Inf
ARIMA(0,0,2)(0,0,1)[7]	1426.549252
ARIMA(0,0,0)(1,0,1)[7]	Inf
ARIMA(1,0,0)(1,0,1)[7]	Inf
ARIMA(0,0,1)(1,0,1)[7]	Inf
ARIMA(0,0,0)(2,0,1)[7]	Inf
ARIMA(0,0,0)(0,0,2)[7]	1618.905610
ARIMA(1,0,0)(0,0,2)[7]	Inf
ARIMA(0,0,1)(0,0,2)[7]	1439.537620
ARIMA(0,0,0)(1,0,2)[7]	Inf

--- Re-estimating best models without approximation ---

ARIMA(1,0,0)(0,0,0)[7]+c -1700.178926

Antes de realizar predições, verificamos se os resíduos são ruído branco, o que indica que o modelo foi bem especificado.

```
# teste de Ljung-Box
data_fit |>
  dplyr::select(ar1) |>
  gg_tsresiduals()
```

```
augment(data_fit) |>
  dplyr::filter(.model == "ar1") |>
  features(.innov, ljung_box, lag = 12, dof = 2)
```

```
# A tibble: 1 x 3
  .model lb_stat lb_pvalue
  <chr>   <dbl>   <dbl>
1 ar1    10.9    0.368
```

A MODELAGEM BOX-JENKINS: SÉRIE II

A série não parece estável. Recomendável transformação para estabilização da variância.

```
lambda = data |>
  features(value, features = guerrero) |>
  (\(x) x[["lambda_guerrero"]])()

data |>
  autoplot(box_cox(value, lambda))
```

