

# Lista III

Alberson Miranda

2022-12-13

```
# configurações
knitr::opts_chunk$set(
  out.width = "100%"
)

# reproducibilidade
set.seed(1)

# pacotes
pacman::p_load(
  "ggplot2"
)

# tema
tema = theme(text = element_text(size = 8))

# dados
load("data/lista_III.RData")
```

**1 Considere o banco de dados dadosSVAR. Este banco contém 3 séries temporais. Com base nessas informações faça o que se pede:**

**A Estime um VAR(p). Analise os resíduos e selecione a melhor ordem para o modelo. Escreva a equação do modelo indicando os elementos das matrizes.**


```

# coercing to tsibble
data = data.frame(
  inflacao = inf,
  juros = juros,
  produto = y,
  index = tsibble::yearquarter(
    seq(
      as.Date("2000-01-01"),
      by = "quarter",
      length.out = length(y)
    )
  )
) |> tsibble::tsibble(index = index)

# plot série
data |>
tidyr::pivot_longer(
  -index,
  names_to = "séries",
  values_to = "valor" ) |>
fabletools::autoplot() +
facet_grid(vars(séries), scales = "free")

```

Plot variable not specified, automatically selected ``.vars = valor``



Para seleção da ordem do VAR(p), usei os critérios de informação de Akaike corrigido (AICc) e o de Schwarz (BIC). Pelo princípio da parcimônia, o modelo escolhido será o de menor ordem dentre os que apresentarem ruído branco. O AICc apontou para um VAR(4), enquanto o BIC para um VAR(5).

```
# ajuste
fit = data |>
  fabletools::model(
    aicc = fable::VAR(vars(inflacao, juros, produto) ~ 1 + AR(p = 0:6), ic = "aicc"),
    bic = fable::VAR(vars(inflacao, juros, produto) ~ 1 + AR(p = 0:6), ic = "bic")
  )

# ordem
fit
```


```
# A mable: 1 x 2
      aicc      bic
  <model>  <model>
1 <VAR(4) w/ mean> <VAR(5) w/ mean>
```

```
# critérios de informação
fabletools::glance(fit)
```

```
# A tibble: 2 x 6
  .model sigma2      log_lik   AIC   AICc   BIC
  <chr>   <list>      <dbl> <dbl> <dbl> <dbl>
1 aicc   <dbl [3 x 3]>    133. -170. -1.54 -57.0
2 bic    <dbl [3 x 3]>    179. -243. 124. -111.
```

Analisando os resíduos, a ACF do VAR(4) ainda demonstrou autocorrelação significativa, enquanto a do VAR(5) se mostrou ruído branco. Assim, selecionamos o VAR(5).

```
# ACF dos resíduos
fit |>
  fabletools::augment() |>
  feasts::ACF(.innov) |>
  autoplot()
```



```
# Portmanteau test
fabletools::augment(fit) |>
  subset(.model == "bic") |>
  fabletools::features(.innov, feasts::ljung_box, lag = 5)
```

```
# A tibble: 3 x 4
  .model .response lb_stat lb_pvalue
  <chr>   <fct>      <dbl>   <dbl>
1 bic    inflacao     8.82    0.117
2 bic    juros       9.38    0.0948
3 bic    produto     1.90    0.863
```

```
# coeficientes
fit |>
  subset(select = bic) |>
  fabletools::report()
```

Series: inflacao, juros, produto  
Model: VAR(5) w/ mean

Coefficients for inflacao:

	lag(inflacao,1)	lag(juros,1)	lag(produto,1)	lag(inflacao,2)
	1.4346	-0.4282	6.2583	-0.7060
s.e.	0.1289	0.2955	8.5931	0.2218
	lag(juros,2)	lag(produto,2)	lag(inflacao,3)	lag(juros,3)
	0.4701	6.9992	0.2142	-0.1166
s.e.	0.3269	4.5723	0.2370	0.2673
	lag(produto,3)	lag(inflacao,4)	lag(juros,4)	lag(produto,4)
	5.6129	-0.4017	0.0960	4.2916
s.e.	4.4977	0.2187	0.2586	4.4633
	lag(inflacao,5)	lag(juros,5)	lag(produto,5)	constant
	0.2900	-0.0319	-1.1704	0.6477
s.e.	0.1277	0.1620	8.9462	0.3236

Coefficients for juros:

	lag(inflacao,1)	lag(juros,1)	lag(produto,1)	lag(inflacao,2)
	0.1373	1.4102	-1.3161	-0.1466
s.e.	0.0433	0.0993	2.8864	0.0745
	lag(juros,2)	lag(produto,2)	lag(inflacao,3)	lag(juros,3)
	-0.5880	-1.3960	0.0367	0.2679
s.e.	0.1098	1.5359	0.0796	0.0898

	lag(produto,3)	lag(inflacao,4)	lag(juros,4)	lag(produto,4)
	-1.4235	-0.0016	-0.2028	-0.2008
s.e.	1.5108	0.0735	0.0869	1.4992
	lag(inflacao,5)	lag(juros,5)	lag(produto,5)	constant
	0.0042	0.0687	-0.7161	0.0764
s.e.	0.0429	0.0544	3.0051	0.1087

Coefficients for produto:

	lag(inflacao,1)	lag(juros,1)	lag(produto,1)	lag(inflacao,2)
	0.0053	-0.0014	0.5377	-0.0066
s.e.	0.0018	0.0041	0.1192	0.0031
	lag(juros,2)	lag(produto,2)	lag(inflacao,3)	lag(juros,3)
	0.0053	-0.1374	-0.0010	-0.0020
s.e.	0.0045	0.0634	0.0033	0.0037
	lag(produto,3)	lag(inflacao,4)	lag(juros,4)	lag(produto,4)
	-0.2272	0.0049	-0.0029	0.8161
s.e.	0.0624	0.0030	0.0036	0.0619
	lag(inflacao,5)	lag(juros,5)	lag(produto,5)	constant
	-0.0018	0.0014	-0.6744	-0.0047
s.e.	0.0018	0.0022	0.1241	0.0045

Residual covariance matrix:

	inflacao	juros	produto
inflacao	0.5813	0.0644	-0.0011
juros	0.0644	0.0656	-0.0003
produto	-0.0011	-0.0003	0.0001

log likelihood = 178.72

AIC = -243.45    AICc = 123.89    BIC = -110.59

A equação do modelo é:

$$\begin{bmatrix} Y_{A,t} \\ Y_{B,t} \\ Y_{C,t} \end{bmatrix} = \begin{bmatrix} \phi_{0A} \\ \phi_{0B} \\ \phi_{0C} \end{bmatrix} + \begin{bmatrix} \phi_{11} & \phi_{12} & \phi_{13} \\ \phi_{21} & \phi_{22} & \phi_{23} \\ \phi_{31} & \phi_{32} & \phi_{33} \end{bmatrix} \begin{bmatrix} Y_{A,t-1} \\ Y_{B,t-1} \\ Y_{C,t-1} \end{bmatrix} + \begin{bmatrix} \phi_{14} & \phi_{15} & \phi_{16} \\ \phi_{24} & \phi_{25} & \phi_{26} \\ \phi_{34} & \phi_{35} & \phi_{36} \end{bmatrix} \begin{bmatrix} Y_{A,t-2} \\ Y_{B,t-2} \\ Y_{C,t-2} \end{bmatrix} + \dots + \begin{bmatrix} \epsilon_{A,t} \\ \epsilon_{B,t} \\ \epsilon_{C,t} \end{bmatrix}$$

$$\begin{bmatrix} Y_{i,t} \\ Y_{j,t} \\ Y_{p,t} \end{bmatrix} = \begin{bmatrix} 0.6477 \\ 0.0764 \\ -0.0047 \end{bmatrix} + \begin{bmatrix} 1.4346 & -0.4282 & 6.2583 \\ 0.1373 & 1.4102 & -1.3161 \\ 0.0053 & -0.0014 & 0.5377 \end{bmatrix} \begin{bmatrix} Y_{i,t-1} \\ Y_{j,t-1} \\ Y_{p,t-1} \end{bmatrix} + \begin{bmatrix} -0.7060 & 0.4701 & 6.9992 \\ -0.1466 & -0.5880 & -1.3960 \\ -0.0066 & 0.0053 & -0.1374 \end{bmatrix} \begin{bmatrix} Y_{i,t-2} \\ Y_{j,t-2} \\ Y_{p,t-2} \end{bmatrix} + \dots + \begin{bmatrix} 0.5813 & 0.0644 & -0.0011 \\ 0.0644 & 0.0656 & -0.0003 \\ -0.0011 & -0.0003 & 0.0001 \end{bmatrix}$$

## B Faça o teste de causalidade de Granger para todas as variáveis.

### 1. Juros x Inflação

A 5% de significância, não há evidências para rejeição da hipótese nula de que a inflação não Granger-causa os juros (e vice-versa).

```
# juros x inflação
lmtest::grangertest(juros ~ inflacao, order = 5, data = data)
```

Granger causality test

Model 1: juros ~ Lags(juros, 1:5) + Lags(inflacao, 1:5)

Model 2: juros ~ Lags(juros, 1:5)

	Res.Df	Df	F	Pr(>F)
1	65			
2	70	-5	2.1235	0.07365

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

```
lmtest::grangertest(inflacao ~ juros, order = 5, data = data)
```

Granger causality test

Model 1: inflacao ~ Lags(inflacao, 1:5) + Lags(juros, 1:5)

Model 2: inflacao ~ Lags(inflacao, 1:5)

	Res.Df	Df	F	Pr(>F)
1	65			
2	70	-5	1.6342	0.1635

## 2. Inflação x Produto

A 5% de significância, não há evidências para rejeição da hipótese nula de que o produto não Granger-causa a inflação (e vice-versa).

```
# produto x inflação
lmtest::grangertest(inflacao ~ produto, order = 5, data = data)
```

Granger causality test

Model 1: inflacao ~ Lags(inflacao, 1:5) + Lags(produto, 1:5)

Model 2: inflacao ~ Lags(inflacao, 1:5)

	Res.Df	Df	F	Pr(>F)
1	65			
2	70	-5	1.7257	0.1412

```
lmtest::grangertest(produto ~ inflacao, order = 5, data = data)
```

Granger causality test

Model 1: produto ~ Lags(produto, 1:5) + Lags(inflacao, 1:5)

Model 2: produto ~ Lags(produto, 1:5)

	Res.Df	Df	F	Pr(>F)
1	65			
2	70	-5	1.7717	0.1311

## 3. Produto x Juros

A 5% de significância, não há evidências para rejeição da hipótese nula de que o produto não Granger-causa os juros (e vice-versa).



```
# produto x juros
lmtest::grangertest(juros ~ produto, order = 5, data = data)
```

Granger causality test

Model 1:  $\text{juros} \sim \text{Lags}(\text{juros}, 1:5) + \text{Lags}(\text{produto}, 1:5)$

Model 2:  $\text{juros} \sim \text{Lags}(\text{juros}, 1:5)$

	Res.Df	Df	F	Pr(>F)
1	65			
2	70	-5	1.5902	0.1753

```
lmtest::grangertest(produto ~ juros, order = 5, data = data)
```

Granger causality test

Model 1:  $\text{produto} \sim \text{Lags}(\text{produto}, 1:5) + \text{Lags}(\text{juros}, 1:5)$

Model 2:  $\text{produto} \sim \text{Lags}(\text{produto}, 1:5)$

	Res.Df	Df	F	Pr(>F)
1	65			
2	70	-5	0.093	0.9931

**C** Estime um SVAR considerando o modelo da letra A e as seguintes restrições para as relações contemporâneas: (i)  $y$  afeta  $\text{inf}$  e  $\text{juros}$ ; (ii)  $\text{inf}$  afeta apenas  $\text{juros}$  porém não impacta  $y$ ; (iii)  $\text{juros}$  não impacta  $y$  ou  $\text{inf}$ .

```
# wrangling
data = cbind(inf, juros, y)

# restrições
mat_A = diag(3)
mat_A[3, 1] = NA
mat_A[1, 2] = NA
mat_A[3, 2] = NA

# ajuste
fit = vars::VAR(data, p = 5)
fit_s = vars::SVAR(fit, Amat = mat_A, estmethod = "direct")

# coeficientes
summary(fit_s)
```

SVAR Estimation Results:

=====

Call:

vars::SVAR(x = fit, estmethod = "direct", Amat = mat\_A)

Type: A-model

Sample size: 76

Log Likelihood: -323.518

Method: direct

Number of iterations: 158

Convergence code: 0

LR overidentification test:

LR overidentification

data: data

Chi^2 = 951, df = 3, p-value <2e-16

Estimated A matrix:

	inf	juros	y
inf	1.000000	-0.982810	0
juros	0.000000	1.000000	0
y	0.001883	0.001882	1

Estimated B matrix:

	inf	juros	y
inf	1	0	0
juros	0	1	0
y	0	0	1

Covariance matrix of reduced form residuals (\*100):

	inf	juros	y
inf	196.5915	98.2810	-0.5551
juros	98.2810	100.0000	-0.3732
y	-0.5551	-0.3732	100.0017

**D Escreva, considerando o modelo estimado na letra c, a equação do SVAR indicando os elementos de todas as matrizes.**

$$\begin{bmatrix} 1 & -0.982810 & 0 \\ 0 & 1 & 0 \\ 0.001883 & 0.001882 & 1 \end{bmatrix} \begin{bmatrix} Y_{i,t} \\ Y_{j,t} \\ Y_{p,t} \end{bmatrix}$$


E os demais coeficientes? Não entendi. É pra inverter a matriz e multiplicar pelos coeficientes do modelo irrestrito? Não está claro como o resultado da função se encaixa com a teoria estudada.

**E Obtenha e analise a função impulso resposta e a decomposição da variância do erro de previsão. Você deve utilizar o VAR(p) ou o SVAR para essa análise? Justifique sua resposta.**

Deve-se usar o VAR estrutural para que os parâmetros estruturais sejam identificáveis. Do contrário, o problema da endogeneidade tornaria impossível atribuir a resposta a uma variável.

```
par(mai = c(0,0,0,0))
# função impulso-resposta: produto
plot(
  vars::irf(
    fit_s,
    impulse = "y",
    response = c("inf", "juros"),
    n.ahead = 10,
    ortho = FALSE,
    cumulative = FALSE
  )
)
```


### SVAR Impulse Response from y



95 % Bootstrap CI, 100 runs

```
# função impulso-resposta: inflação
plot(
  vars::irf(
    fit_s,
    impulse = "inf",
    response = c("y", "juros"),
    n.ahead = 10,
    ortho = FALSE,
    cumulative = FALSE
  )
)
```


### SVAR Impulse Response from inf



95 % Bootstrap CI, 100 runs


```
# função impulso-resposta: juros
plot(
  vars::irf(
    fit_s,
    impulse = "juros",
    response = c("y", "inf"),
    n.ahead = 10,
    ortho = FALSE,
    cumulative = FALSE
  )
)
```

## SVAR Impulse Response from juros



95 % Bootstrap CI, 100 runs

```
# decomposição da variância  
plot(  
  vars::fevd(fit_s, n.ahead = 10)  
)
```



2 O arquivo `questão_2` contém dados mensais sobre os índices de preços do consumidor no Japão, Canadá, Suíça e EUA. Além disso, conta com as taxas de câmbio bilaterais com o Estados Unidos. As variáveis são nomeadas, por exemplo, como `JAPANCPI` = índice de preços do Japão e `JAPANEX` = taxa de câmbio Japão/EUA. Para essa questão considere os dados até 12/2012

A Obtenha o logaritmo das séries. Avalie se possuem raiz unitária.

```
# carregando funções
library(dplyr, include.only = c("mutate", "across"))
```

Warning: package 'dplyr' was built under R version 4.2.2

```
library(tidyselect, include.only = "where")
```

Warning: package 'tidyselect' was built under R version 4.2.2

```
library(urca)
```

Warning: package 'urca' was built under R version 4.2.2

```
# importando dados
data = readxl::read_excel("data/dados.xlsx")

# convertendo data
data = subset(data, ENTRY <= as.Date("2012-12-01")) |>
  mutate(ENTRY = tsibble::yearmonth(ENTRY)) |>
  mutate(across(where(is.character), as.numeric))


# coercing to tsibble
data = tsibble::tsibble(data, index = ENTRY)

# séries em logs
data_log = data |>
  mutate(across(where(is.numeric), log))
```

```
# plot série
data |>
tidyr::pivot_longer(
  -ENTRY,
  names_to = "séries",
  values_to = "valor") |>
fabletools::autoplot() +
facet_grid(vars(séries), scales = "free") +
labs(
  x = "",
  title = "SÉRIES EM NÍVEL"
) + tema
```


Plot variable not specified, automatically selected ``.vars = valor``





```
# plot série em log
data_log |>
  tidyr::pivot_longer(
    -ENTRY,
    names_to = "séries",
    values_to = "valor") |>
  fabletools::autoplot() +
  facet_grid(vars(séries), scales = "free") +
  labs(
    x = "",
    title = "SÉRIES EM LOG"
  ) + tema
```

Plot variable not specified, automatically selected `vars = valor`



A seguir, os testes de raiz unitária.

1. JAPANEX: o modelo com tendência se mostrou bem especificado e  $\hat{\tau} \not< \tau$ , de forma que não há evidências para rejeitar a hipótese nula de raiz unitária.
2. JAPANCP: a especificação com tendência foi não significativa para a variável de tendência determinística. Passando para a especificação com *drift*, o modelo é bem especificado.  $\hat{\tau} < \tau$  a 1% de significância, então pode-se rejeitar a hipótese nula e a série é estacionária.
3. USCPI: a especificação com tendência foi não significativa para a variável de tendência determinística. Passando para a especificação com *drift*, o modelo é bem especificado.  $\hat{\tau} < \tau$  a 5% de significância, então pode-se rejeitar a hipótese nula e a série é estacionária.

```
# Augmented-Dickey-Fuller test JAPANEX
data_log |>
  (\(x) ur.df(x$JAPANEX, selectlags = "AIC", type = "trend", lags = 12))() |>
  summary()
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression trend

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.089837	-0.015769	0.002142	0.017412	0.066762

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	1.188e-01	4.236e-02	2.805	0.00525	**
z.lag.1	-2.205e-02	7.616e-03	-2.895	0.00398	**
tt	-4.642e-05	2.141e-05	-2.168	0.03069	*
z.diff.lag1	3.174e-01	4.692e-02	6.764	4.29e-11	***
z.diff.lag2	-3.609e-02	4.930e-02	-0.732	0.46456	
z.diff.lag3	6.282e-02	4.940e-02	1.272	0.20413	
z.diff.lag4	2.816e-02	4.935e-02	0.571	0.56855	
z.diff.lag5	-6.194e-02	4.947e-02	-1.252	0.21121	
z.diff.lag6	-4.740e-02	4.966e-02	-0.954	0.34041	
z.diff.lag7	-5.684e-03	4.983e-02	-0.114	0.90923	
z.diff.lag8	1.136e-01	4.993e-02	2.275	0.02340	*
z.diff.lag9	4.713e-02	5.017e-02	0.939	0.34804	
z.diff.lag10	7.079e-03	5.006e-02	0.141	0.88761	
z.diff.lag11	1.323e-01	4.788e-02	2.764	0.00595	**

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02555 on 441 degrees of freedom

Multiple R-squared: 0.1636, Adjusted R-squared: 0.139

F-statistic: 6.638 on 13 and 441 DF, p-value: 1.217e-11

Value of test-statistic is: -2.8952 3.5014 4.7278

Critical values for test statistics:

	1pct	5pct	10pct
tau3	-3.98	-3.42	-3.13
phi2	6.15	4.71	4.05
phi3	8.34	6.30	5.36

```
# Augmented-Dickey-Fuller test JAPANCPI
data_log |>
  (\(x) ur.df(x$JAPANCPI, selectlags = "AIC", type = "trend", lags = 12))() |>
  summary()
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression trend

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.0136373	-0.0020955	0.0001673	0.0019578	0.0169375

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	4.611e-02	1.507e-02	3.059	0.002354	**
z.lag.1	-7.950e-03	2.717e-03	-2.927	0.003605	**
tt	-2.382e-06	2.415e-06	-0.986	0.324494	
z.diff.lag1	-1.961e-02	4.196e-02	-0.467	0.640504	
z.diff.lag2	-1.581e-01	4.179e-02	-3.784	0.000176	***
z.diff.lag3	-4.627e-02	4.180e-02	-1.107	0.268902	
z.diff.lag4	-4.707e-02	4.132e-02	-1.139	0.255172	
z.diff.lag5	8.091e-02	4.132e-02	1.958	0.050859	.
z.diff.lag6	1.585e-02	4.139e-02	0.383	0.701938	
z.diff.lag7	4.439e-02	4.109e-02	1.080	0.280532	
z.diff.lag8	-1.886e-02	4.068e-02	-0.464	0.643065	
z.diff.lag9	-1.289e-02	4.062e-02	-0.317	0.751109	
z.diff.lag10	-1.919e-01	3.981e-02	-4.820	1.98e-06	***
z.diff.lag11	3.791e-02	4.049e-02	0.936	0.349664	
z.diff.lag12	4.209e-01	3.941e-02	10.680	< 2e-16	***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.003805 on 440 degrees of freedom

Multiple R-squared: 0.4758, Adjusted R-squared: 0.4591

F-statistic: 28.53 on 14 and 440 DF, p-value: < 2.2e-16

Value of test-statistic is: -2.9265 6.0246 8.2128

Critical values for test statistics:

	1pct	5pct	10pct
tau3	-3.98	-3.42	-3.13
phi2	6.15	4.71	4.05
phi3	8.34	6.30	5.36

```
data_log |>
  (\(x) ur.df(x$JAPANCPI, selectlags = "AIC", type = "drift", lags = 12))() |>
  summary()
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression drift

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.0136165	-0.0020269	0.0001043	0.0019119	0.0170195

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	0.052923	0.013396	3.951	9.07e-05	***
z.lag.1	-0.009278	0.002360	-3.931	9.82e-05	***
z.diff.lag1	-0.016182	0.041815	-0.387	0.698946	
z.diff.lag2	-0.155083	0.041677	-3.721	0.000224	***
z.diff.lag3	-0.042915	0.041662	-1.030	0.303536	
z.diff.lag4	-0.044386	0.041226	-1.077	0.282215	
z.diff.lag5	0.083437	0.041243	2.023	0.043668	*
z.diff.lag6	0.017866	0.041338	0.432	0.665808	
z.diff.lag7	0.045767	0.041062	1.115	0.265636	
z.diff.lag8	-0.017801	0.040660	-0.438	0.661748	

```

z.diff.lag9  -0.011524    0.040594   -0.284 0.776622
z.diff.lag10 -0.191254    0.039807   -4.805 2.13e-06 ***
z.diff.lag11  0.039503    0.040460    0.976 0.329439
z.diff.lag12  0.421492    0.039403   10.697 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```

Residual standard error: 0.003805 on 441 degrees of freedom
Multiple R-squared:  0.4746,    Adjusted R-squared:  0.4592
F-statistic: 30.65 on 13 and 441 DF,  p-value: < 2.2e-16

```

Value of test-statistic is: -3.9311 8.551

Critical values for test statistics:

```

      1pct  5pct 10pct
tau2 -3.44 -2.87 -2.57
phi1  6.47  4.61  3.79

```

```

# Augmented-Dickey-Fuller test USCPI
data_log |>
  (\(x) ur.df(x$USCPI, selectlags = "AIC", type = "trend", lags = 12))() |>
  summary()

```

```

#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

```

Test regression trend

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

```

      Min       1Q   Median       3Q      Max
-0.0131143 -0.0010917 -0.0000688  0.0013054  0.0098055

```

Coefficients:

```

              Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.456e-02  6.032e-03   2.415  0.01616 *

```

```

z.lag.1      -2.495e-03  1.156e-03  -2.158  0.03148  *
tt           3.990e-06  3.415e-06   1.168  0.24326
z.diff.lag1  5.492e-01  4.667e-02  11.769  < 2e-16 ***
z.diff.lag2 -1.156e-01  5.313e-02  -2.175  0.03014  *
z.diff.lag3  5.834e-02  5.322e-02   1.096  0.27358
z.diff.lag4  6.720e-02  5.310e-02   1.266  0.20630
z.diff.lag5 -4.435e-02  5.312e-02  -0.835  0.40425
z.diff.lag6  4.469e-02  5.322e-02   0.840  0.40148
z.diff.lag7  3.175e-02  5.311e-02   0.598  0.55029
z.diff.lag8  6.922e-03  5.317e-02   0.130  0.89648
z.diff.lag9  6.624e-02  5.302e-02   1.249  0.21222
z.diff.lag10 6.207e-02  5.281e-02   1.175  0.24044
z.diff.lag11 1.455e-01  5.253e-02   2.770  0.00584 **
z.diff.lag12 -1.926e-01  4.622e-02  -4.166  3.73e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Residual standard error: 0.002299 on 440 degrees of freedom  
Multiple R-squared: 0.5108, Adjusted R-squared: 0.4952  
F-statistic: 32.82 on 14 and 440 DF, p-value: < 2.2e-16

Value of test-statistic is: -2.1578 5.9793 5.7993

Critical values for test statistics:

```

      1pct  5pct 10pct
tau3 -3.98 -3.42 -3.13
phi2  6.15  4.71  4.05
phi3  8.34  6.30  5.36

```

```

data_log |>
  (\(x) ur.df(x$USCPI, selectlags = "AIC", type = "drift", lags = 12))() |>
  summary()

```

```

#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

```

Test regression drift

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.0130021	-0.0011428	-0.0000459	0.0012399	0.0098731

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	0.0080913	0.0023871	3.390	0.000763	***
z.lag.1	-0.0012197	0.0003814	-3.198	0.001485	**
z.diff.lag1	0.5509582	0.0466631	11.807	< 2e-16	***
z.diff.lag2	-0.1153855	0.0531489	-2.171	0.030465	*
z.diff.lag3	0.0592511	0.0532394	1.113	0.266349	
z.diff.lag4	0.0673460	0.0531177	1.268	0.205516	
z.diff.lag5	-0.0442399	0.0531425	-0.832	0.405591	
z.diff.lag6	0.0456604	0.0532345	0.858	0.391512	
z.diff.lag7	0.0319271	0.0531296	0.601	0.548197	
z.diff.lag8	0.0072682	0.0531880	0.137	0.891368	
z.diff.lag9	0.0670225	0.0530364	1.264	0.207003	
z.diff.lag10	0.0619684	0.0528296	1.173	0.241435	
z.diff.lag11	0.1455501	0.0525521	2.770	0.005849	**
z.diff.lag12	-0.1927904	0.0462384	-4.169	3.68e-05	***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.0023 on 441 degrees of freedom

Multiple R-squared: 0.5093, Adjusted R-squared: 0.4948

F-statistic: 35.21 on 13 and 441 DF, p-value: < 2.2e-16

Value of test-statistic is: -3.1976 8.2794

Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.44	-2.87	-2.57
phi1	6.47	4.61	3.79



**B Estime a relação de longo prazo entre  $\log(\text{japanex})$  em função de  $\log(\text{japanmpi})$  e  $\log(\text{uscpi})$ . Com base na metodologia de Engle-Granger, teste para cointegração.**

Não podem ser cointegradas pois  $\log(JAPANCPI)$  e  $\log(USCPI)$  são estacionárias. Se não o fossem, o procedimento seria realizar a regressão e verificar se os resíduos são estacionários.

Neste caso, a especificação correta para o teste ADF seria sem tendência e sem drift. Se acordo com o resultado, rejeitaria a hipótese nula e os resíduos seriam estacionários. Entretanto, a ACF é de uma série com raiz unitária, vide decaimento lento. Verificar.

```
# modelo
modelo = lm(log(JAPANEX) ~ log(JAPANCPI) + log(USCPI), data = data)
summary(modelo)
```

Call:

```
lm(formula = log(JAPANEX) ~ log(JAPANCPI) + log(USCPI), data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.41312	-0.10770	-0.01184	0.08863	0.42784

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	9.97459	0.36593	27.258	<2e-16 ***
log(JAPANCPI)	-0.10420	0.10667	-0.977	0.329
log(USCPI)	-0.76823	0.04505	-17.054	<2e-16 ***

---


Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.156 on 465 degrees of freedom

Multiple R-squared: 0.8336, Adjusted R-squared: 0.8329


F-statistic: 1165 on 2 and 465 DF, p-value: < 2.2e-16

```
# plots dos resíduos
plot.ts(modelo$residuals)
```



```
acf(modelo$residuals)
```

## Series modelo\$residuals



```
# teste de raiz unitária
summary(ur.df(modelo$residuals, selectlags = "AIC", type = "trend", lags = 12))
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression trend

```
Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-0.08821 -0.01514  0.00153  0.01772  0.07122
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
```

```

(Intercept) -2.962e-04  2.506e-03  -0.118  0.905962
z.lag.1      -2.833e-02  8.339e-03  -3.397  0.000743 ***
tt           1.880e-06  9.167e-06   0.205  0.837601
z.diff.lag1  3.261e-01  4.673e-02   6.979  1.09e-11 ***
z.diff.lag2 -3.089e-02  4.924e-02  -0.627  0.530770
z.diff.lag3  7.351e-02  4.932e-02   1.491  0.136784
z.diff.lag4  2.834e-02  4.936e-02   0.574  0.566089
z.diff.lag5 -5.473e-02  4.945e-02  -1.107  0.268932
z.diff.lag6 -4.405e-02  4.960e-02  -0.888  0.374995
z.diff.lag7  6.103e-03  4.975e-02   0.123  0.902437
z.diff.lag8  1.098e-01  4.984e-02   2.202  0.028174 *
z.diff.lag9  5.479e-02  5.005e-02   1.095  0.274299
z.diff.lag10 1.293e-02  4.995e-02   0.259  0.795914
z.diff.lag11 1.425e-01  4.775e-02   2.984  0.003006 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Residual standard error: 0.02561 on 441 degrees of freedom  
Multiple R-squared: 0.1737, Adjusted R-squared: 0.1494  
F-statistic: 7.133 on 13 and 441 DF, p-value: 1.152e-12

Value of test-statistic is: -3.3969 3.9168 5.866

Critical values for test statistics:

```

      1pct  5pct 10pct
tau3 -3.98 -3.42 -3.13
phi2  6.15  4.71  4.05
phi3  8.34  6.30  5.36

```

```
summary(ur.df(modelo$residuals, selectlags = "AIC", type = "drift", lags = 12))
```

```

#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

```

Test regression drift

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.088545	-0.015157	0.001494	0.017818	0.070956

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	0.0001549	0.0011997	0.129	0.897336
z.lag.1	-0.0284435	0.0083101	-3.423	0.000678 ***
z.diff.lag1	0.3263204	0.0466713	6.992	1.01e-11 ***
z.diff.lag2	-0.0307813	0.0491810	-0.626	0.531718
z.diff.lag3	0.0736624	0.0492593	1.495	0.135524
z.diff.lag4	0.0284106	0.0493009	0.576	0.564727
z.diff.lag5	-0.0546285	0.0493909	-1.106	0.269309
z.diff.lag6	-0.0440150	0.0495471	-0.888	0.374838
z.diff.lag7	0.0062232	0.0496966	0.125	0.900403
z.diff.lag8	0.1098097	0.0497874	2.206	0.027928 *
z.diff.lag9	0.0548154	0.0499987	1.096	0.273528
z.diff.lag10	0.0129214	0.0498931	0.259	0.795770
z.diff.lag11	0.1424135	0.0477015	2.986	0.002988 **

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02558 on 442 degrees of freedom

Multiple R-squared: 0.1737, Adjusted R-squared: 0.1512

F-statistic: 7.741 on 12 and 442 DF, p-value: 4.08e-13

Value of test-statistic is: -3.4228 5.8668

Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.44	-2.87	-2.57
phi1	6.47	4.61	3.79

```
summary(ur.df(modelo$residuals, selectlags = "AIC", type = "none", lags = 12))
```

```
#####  
# Augmented Dickey-Fuller Test Unit Root Test #  
#####
```

Test regression none

Call:

```
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.088397	-0.015003	0.001643	0.017971	0.071108

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
z.lag.1	-0.028445	0.008301	-3.427	0.000668	***
z.diff.lag1	0.326352	0.046619	7.000	9.5e-12	***
z.diff.lag2	-0.030763	0.049126	-0.626	0.531508	
z.diff.lag3	0.073698	0.049204	1.498	0.134894	
z.diff.lag4	0.028434	0.049246	0.577	0.563975	
z.diff.lag5	-0.054584	0.049335	-1.106	0.269157	
z.diff.lag6	-0.043992	0.049492	-0.889	0.374550	
z.diff.lag7	0.006280	0.049639	0.127	0.899382	
z.diff.lag8	0.109853	0.049731	2.209	0.027689	*
z.diff.lag9	0.054848	0.049943	1.098	0.272701	
z.diff.lag10	0.012964	0.049837	0.260	0.794878	
z.diff.lag11	0.142438	0.047648	2.989	0.002951	**

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02555 on 443 degrees of freedom

Multiple R-squared: 0.1737, Adjusted R-squared: 0.1513

F-statistic: 7.761 on 12 and 443 DF, p-value: 3.707e-13

Value of test-statistic is: -3.4268

Critical values for test statistics:

	1pct	5pct	10pct
tau1	-2.58	-1.95	-1.62

**C Construa, caso necessário, o modelo de correção de erros para  $\log(\text{japanex})$ .**

Como o sinal do vetor de erro é positivo e não significativo, não há cointegração.

```
vecm = lm(diff(log(JAPANEX))[-1] ~ modelo$residuals[-1:-2] + log(JAPANCPI[-1:-2]) + log(USCPI[-1:-2]) + diff(log(JAPANEX))[-1:-2]), data = data)
summary(vecm)
```

Call:

```
lm(formula = diff(log(JAPANEX))[-1] ~ modelo$residuals[-1:-2] +
    log(JAPANCPI[-1:-2]) + log(USCPI[-1:-2]) + diff(log(JAPANEX))[-(length(data$JAPANEX) -
    1)]), data = data)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.094665	-0.014498	0.001057	0.017992	0.074983

Coefficients:

	Estimate	Std. Error	t value
(Intercept)	0.036972	0.063263	0.584
modelo\$residuals[-1:-2]	0.007310	0.007781	0.939
log(JAPANCPI[-1:-2])	-0.015335	0.018285	-0.839
log(USCPI[-1:-2])	0.008127	0.007603	1.069
diff(log(JAPANEX))[-(length(data\$JAPANEX) - 1)]	0.309677	0.044616	6.941

Pr(>|t|)

(Intercept)	0.559
modelo\$residuals[-1:-2]	0.348
log(JAPANCPI[-1:-2])	0.402
log(USCPI[-1:-2])	0.286
diff(log(JAPANEX))[-(length(data\$JAPANEX) - 1)]	1.33e-11 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02588 on 461 degrees of freedom

Multiple R-squared: 0.1057, Adjusted R-squared: 0.0979

F-statistic: 13.62 on 4 and 461 DF, p-value: 1.68e-10